

# 基于风速升降特征的短期风电功率预测

叶小岭<sup>1,2</sup>, 陈浩<sup>1</sup>, 郭晓杰<sup>1</sup>, 邓华<sup>1,2</sup>, 王雅晨<sup>1</sup>

(1. 南京信息工程大学信息与控制学院, 江苏 南京 210044; 2. 南京信息工程大学  
气象灾害预报预警与评估协同创新中心, 江苏 南京 210044)

**摘要:** 为提高短期风电功率预测精度, 提出了基于风速升降特征的短期风电功率预测方法。该方法分析风速上升或下降对风力发电的影响, 根据风速升降特征, 为风速添加标记值, 增加训练样本维度, 从而提高功率预测精度。用上海某风电场 2014 年 9 月至 2015 年 9 月数据对算法进行验证, 并对比最小二乘支持向量机(LSSVM)、极限学习机(ELM)、遗传 BP 神经网络(GA-BP)三种方法的预测结果。实验结果表明, 在风电功率预测中引入风速升降特征能够明显提高了模型的预测精度, 适合风电场的短期功率预测。

**关键词:** 短期风电功率预测; 风速升降特征; 特征值; LSSVM; ELM; GA-BP

## Short-term wind power prediction based on the UP-DOWN-features of wind speed

YE Xiaoling<sup>1,2</sup>, CHEN Hao<sup>1</sup>, GUO Xiaojie<sup>1</sup>, DENG Hua<sup>1,2</sup>, WANG Yachen<sup>1</sup>

(1. Nanjing University of Information Science & Technology, Nanjing 210044, China; 2. Collaborative Innovation  
Center on Forecast and Evaluation of Meteorological Disasters, Nanjing University of  
Information Science & Technology, Nanjing 210044, China)

**Abstract:** In order to improve the accuracy of short-term wind power prediction, a short-term wind power prediction method based on UP-DOWN-features of wind speed is presented. By analyzing the change of output power caused by UP-DOWN-features, wind speed is labeled by the features in every moment to increase the training dimensions and then the prediction accuracy is improved. The data from a wind farm in Shanghai from September 2014 to September 2015 is used. By comparing the prediction results of Least Squares Support Vector Machine (LSSVM), Extreme Learning Machine (ELM), Genetic Algorithms-BP Neural Networks (GA-BP), the prediction accuracy of the model which has added the UP-DOWN-features will be enhanced, and experiments show that it is suitable for short-term wind power prediction.

**Key words:** short-term wind power prediction; UP-DOWN-features; LSSVM; ELM; GA-BP

## 0 引言

风的波动性、随机性和间歇性等特点决定了风力发电的不稳定性, 故准确的短期风电功率预测, 是电网稳定安全的前提之一<sup>[1]</sup>。

短期风电功率预测方法<sup>[2-3]</sup>可分为物理方法、统计方法、人工智能方法以及以上方法的组合<sup>[4-5]</sup>。物理方法是以数值天气预报(Numerical Weather Prediction, NWP)的预测结果为基础, 考虑风场的地

形等物理因素, 根据风电机组功率曲线进行功率预测。统计、智能方法是以风电场实测时序序列或NWP提供的风速预测时序序列为基础, 通过该时间序列数据建立预测模型, 进而预测风速或发电功率。早期采用的统计或智能方法有滑动平均自回归法<sup>[6]</sup>、人工神经网络<sup>[7]</sup>、支持向量机(SVM)<sup>[8-9]</sup>等单一方法。理论上, 风到功率的转化有确定的物理规律。而实际情况下, 由于受到多种客观因素影响, 单一方法难以刻画风到功率的转化关系, 且单一方法本身存在局限性, 故小波分解<sup>[10]</sup>、遗传算法(GA)<sup>[11]</sup>、粒子群算法(PSO)<sup>[12]</sup>等被引入。如文献[10]提出了基于小波-BP神经网络的预测模型, 解决BP神经网络不能完全映射原始风速及功率序列日特性

基金项目: 江苏省高校优势学科建设工程资助项目(PAPD); 江苏省六大人才高峰项目(WLW-021); 中国气象局软科学研究课题(SK20120146)共同资助

的缺陷;文献[12]为克服支持向量机依赖经验选择学习参数的弊端,引入基于模拟退火法的粒子群算法(PSOA)优化支持向量机参数;文献[13]为减小单一模型存在的较大误差,提出一种组合短期风速预测模型,该模型通过离散Hopfield识别历史数据中与待测数据最相似的数据作为训练样本,将SVM、BP神经网络和ELMAN神经网络的预测结果作为输入向量,经GRNN进行非线性组合预测,提高了预测精度。考虑到不同风电场或风电机组的风速或功率在空间上存在相关性,从而空间相关性被许多国内外研究者应用于风电功率预测中<sup>[14]</sup>。文献[15]为了提高空间相关性预测的时间尺度和空间距离,利用季风在地理空间上的大范围一致性,提高了预测结果的可靠性。

上述类型的方法,在预测精度上都有提高,但其都是从预测方法本身或空间相关性方面考虑,而在风速升降特征对风电功率预测的影响方面研究较少。

基于此,本文根据风速的升降特征提出上升风和下降风的概念,通过设定一定阈值给每一时刻的风速标记特征值,增加了训练数据维度,并用LSSVM、ELM、GA-BP三种方法,验证了风速升降特征在风电功率预测中的合理性,与不考虑风速升降特征相比较,其明显提高了模型的预测精度。

## 1 风速升降与功率的关系

本文数据来源于上海某风电场2014年9月至2015年9月全年的测风塔数据,时间分辨率为5 min,风机型号为上海电气W2000,30台风机型号相同,其切入风速为3 m/s,额定风速12 m/s,切出风速25 m/s,额定功率2 MW,风轮直径93 m,扫风面积6 793 m<sup>2</sup>。

图1是风电场实测风速与功率的散点图,由图1可知,同个风速点对应多个功率值,风机的输出功率并不遵循标准的风电功率曲线,而是分布在一个区间内,造成这种现象一方面由于风机输出功率大小受空气密度和尾流效应等因素影响;另一方面,风机根据测风仪指示风向调整方向的过程中存在滞后性,使风机捕获的风速与实际风速存在偏差,其引入误差的同时导致风速相同而输出功率不同;其次,风机的老化磨损等因素也会导致误差产生<sup>[16]</sup>。而实际上,相比较风向变化,风速的波动对风机的输出功率也有较大的影响<sup>[17-18]</sup>。

为对比风速和风向的波动程度,将实测风速、风向数据归一化,如图2所示,图中a为风速波动曲线,b为风向波动曲线。分别求其方差,可得风向方差为0.015,风速方差为0.022,风速数据的离

散程度较大。由图2可知,风向变化相对平稳,风速波动明显较大,所以风速变化对输出功率也有较大影响。




图1 风电功率散点图

Fig. 1 Scatterplot of wind power




图2 风速风向波动曲线

Fig. 2 Fluctuation curve of the speed and direction of wind

风力发电过程,是一个风能转化为机械能,机械能再转化为电能的物理过程。当风速上升或下降时,由于存在惯性,其实际发电功率将会偏离正常值。惯性是物体的一种固有属性,是始终存在的,表现为物体对其运动状态变化的一种阻抗程度,质量是对物体惯性大小的量度,由于风机桨叶质量较大,故惯性较大。当风速由小变大时,由于存在较大的惯性,桨叶对其运动状态变化存在较大阻抗,其实际转速是缓慢增大趋势,实际发电功率也因此缓慢增大,所以该时间段内风速对应的功率值将会偏离标准的风电功率曲线;同理,当风速由大变小时,由于阻抗作用,桨叶实际转速缓慢减小,实际发电功率缓慢减小,所以该时间段内风速对应的功率值也将会偏离标准的风电功率曲线;由于桨叶转动时存在惯性较大,所以作用力变化大小需达到一定值,才会对其产生影响。

基于此,本文首先定义上升风和下降风,通过为风速添加标记值将上升风和下降风分离,并将其分别绘成散点图与风速功率曲线对比,说明风速升降特征对实际输出功率的影响,最后验证标记特征值方法的合理性。

### 1.1 上升风下降风定义

设  $i$  和  $i+1$  时刻风速分别为  $v_i$  和  $v_{i+1}$ ,  $m$  为阈值, 且  $m > 0$ 。

若  $v_i < v_{i+1}$  且  $v_{i+1} - v_i \geq m$ , 则  $(i, i+1)$  时间段的风速定义为上升风, 标记为 1。

若  $v_i > v_{i+1}$  且  $v_i - v_{i+1} \geq m$ , 则  $(i, i+1)$  时间段的风速定义为下降风, 标记为 -1。

若  $v_i = v_{i+1}$  或  $|v_i - v_{i+1}| < m$ , 则  $(i, i+1)$  时间段的风速定义为平稳, 标记为 0。

### 1.2 风速升降特征的标记方法

设  $v_i$  为某一时刻风速, 阈值  $m = (0.1, 0.2, \dots, 1)$ , 将上升风标记特征值为 1, 将下降风标记特征值为 -1, 将平稳风标记为 0, 添加一个新的训练特征, 增加训练样本维度。如表 1 所示, 当  $m = 0.3$  时, 某一段风速及其特征值。

表 1 风速特征值表

Table 1 Table of speed and features

风速/ (m/s)	特征值	风速/ (m/s)	特征值	风速/ (m/s)	特征值
5.91	1	4.20	0	4.83	0
5.53	-1	4.63	1	4.19	-1
4.80	-1	4.92	0	4.18	0
4.27	-1	4.09	-1	3.78	-1
4.06	0	4.58	1	4.08	1

### 1.3 风速功率等级表和风速功率曲线

为描述风速的升降特征对功率的影响, 本文提出的风速功率等级表的概念, 设风速的范围为  $[0, v_{co}]$ , 将风速划分成  $n$  个等级, 根据风机参数, 取  $d$  为  $0.05 \text{ m/s}$ , 风速的范围为  $[0, 25]$ , 各等级为  $[0, d), [d, 2d), \dots, [(n-1)d, nd)$ , 则  $n = 500$ , 其中  $nd = v_{co}$ ,  $v_{co}$  为切出风速, 单位为  $\text{m/s}$ 。  $p_i$  为该等级上第  $i$  个风速对应的功率,  $l$  表示风速功率的等级,  $P_L$  为第  $L$  等级内所有功率均值, 公式为

$$P_L = \frac{\sum_{i=1}^m p_i}{m} \quad (1)$$

针对同一型号风机, 使用全年风速功率数据制成风速功率等级表, 并绘制风速功率曲线, 如图 3 所示。风速功率曲线平均同一等级中风速的功率, 相对比较平稳, 具有较高的风速功率走向代表意义。

### 1.4 风速升降特征对功率的影响

将  $m$  值设为 0.3, 为每台风机每个时刻的风速标记特征值, 以一号风机为例, 统计所有特征值为 1、-1、0 的风速, 分别绘成风速功率散点图, 并与风速功率曲线对比, 如图 4 所示。




图 3 风速功率曲线

Fig. 3 Curves of wind and power





图 4 上升风下降风与风电功率曲线对比

Fig. 4 Comparison of up-down wind and wind-speed table

图 4 中, a 表示特征值为 1 时, 上升风与风速功率曲线对比图; b 表示特征值为 -1 时, 下降风与风速功率曲线对比图。

如图 4 所示, 通过对比上升风下降风散点和功率曲线, 上升风功率散点大部分位于风电功率曲线下方, 下降风的功率散点大部分位于风电功率曲线上方。验证了风速升降特征对输出功率的影响。由于惯性, 当风速上升时, 桨叶转动存在阻力, 其实际发电功率将大部分小于风速功率曲线; 风速下降时则相反。基于此特征, 本文根据上升风下降风的定义, 通过给每一时刻的风速标记特征值, 并训练模型, 从而提高功率预测精度。

## 2 预测方法

### 2.1 ELM 预测

ELM<sup>[19-20]</sup>网络初始权值和隐含层阈值随机产生, 通过最小二乘的方法计算输出层的权值。给定  $N$  个不同的样本  $(x_j, t_j) \in R^n \times R^m$ , 对于有  $\tilde{N}$  个隐含节点, 激活函数为  $g(x)$  单层隐前向神经网络的数学模型, 表示为

$$\sum_{i=1}^{\hat{N}} \beta_i g_i(x_j) = \sum_{i=1}^{\hat{N}} (\beta_i g \omega_i x_i + b_i) = o_j \quad (2)$$

式中:  $(\omega_i, b_i)$  是隐节点参数且随机产生;  $\beta_i$  是第  $i$  个隐节点的权值;  $j=1, 2, \dots, N$ 。若模型的实际输出与测试输出相符, 则

$$\sum_{i=1}^{\hat{N}} \beta_i g_i(\omega_i x_i + b_i) = t_j, j=1, 2, \dots, N \quad (3)$$

可简写为  $H\beta = T$ 。  $H$  为网络隐含层输出矩阵, 在 ELM 中, 输出权值和偏差可随机给定, 这样原始的前馈神经网络训练可变为一个求解输出权值矩阵的最小二成解的问题, 输出权值矩阵  $\beta$  由下公式可求得:  $\tilde{\beta} = H^+ T$ ,  $H^+$  为隐含层输出矩阵  $H$  的 Moore-Penrose 广义逆。

## 2.2 LSSVM 预测

LSSVM 由 Sunken 在文献[21]中提出, 利用非线性映射  $\varphi$  将样本空间映射到特征空间  $\varphi(x)$ , 并在高维空间中构造决策函数  $f(x) = \omega\varphi(x) + b$ , 利用结构风险最小化原则, 构造损失函数  $J(w, e)$ , 将解二次规划问题转化为解线性方程组。  $\xi_i$  为松弛变量,  $C$  为正规化参数。

$$\begin{cases} \min_{w, b, e} J(w, e) = \frac{1}{2} w^T w + \frac{C}{2} \sum_{i=1}^l \xi_i^2, \\ \text{s.t. } y_i = w \cdots \varphi(x_i) + b + \xi_i, i=1, 2, \dots, l \end{cases} \quad (4)$$

引入拉格朗日法求解方程组, 可以得到

$$L(w, b, \xi, \alpha) = J(w, e) - \sum_{i=1}^l \alpha_i \{w\varphi(x_i) + b + \xi_i - y_i\} \quad (5)$$

$\alpha_i$  为拉格朗日乘子, 根据 KKT 条件可知

$$\begin{cases} w = \sum_{i=1}^l \alpha_i \varphi(x_i) \\ \sum_{i=1}^l \alpha_i = 0 \end{cases} \quad (6)$$

通过核函数将上述的优化过程转化为线性方程求解, 核函数为  $K(x_i, y_j) = \varphi(x_i)\varphi(x_j)$ , 用最小二乘法求解转化后的线性方程组, 即 LSSVM 的输出为

$$y(x) = \sum_{i=1}^l a_i k(x, x_i) + b \quad (7)$$

式中,  $k(x, x_i)$  为核函数, 由式(7)可知, LSSVM 的训练问题归结为一个线性方程组的求解问题。

## 2.3 GA-BP 预测

BP 神经网络是非线性不确定性数学模型, 是一种多层前向型神经网络, 采用梯度下降法调整权值和阈值, 使误差值最小。对于维度为  $h$  的训练样本  $N$ , 目标函数为

$$\min J = \frac{1}{2} \sum_{p=1}^N \sum_{k=1}^h (y_k^p - o_k^p)^2 \quad (8)$$

式中:  $o_k^p$  为输出节点  $k$  在样本  $p$  作用时输出,  $y_k^p$  为在样本  $p$  作用时输出节点  $k$  的目标值。

引入遗传算法<sup>[22]</sup>, 改善 BP 神经网络隐含层神经元数目、初始权值、阈值无确定的指标。在得到 BP 网络后构建结构权值阈值确定的神经网络计算适应度函数, 误差绝对值和  $E$  作为个体适应度值  $F$ 。

$$F = k \left( \sum_{i=1}^n \text{abs}(y_i - o_i) \right) \quad (9)$$

式中:  $n$  为输出节点数;  $y_i$  为 BP 网络第  $i$  个节点的期望输出;  $k$  为系数;  $o_i$  为第  $i$  节点的预测输出。

基于适应度比例的选择策略, 计算每个个体  $i$  的选择概率  $p_i$ 。

$$f_i = k / F_i \quad (10)$$

$$p_i = \frac{f_i}{\sum_{j=1}^N f_j} \quad (11)$$

式中:  $F_i$  为个体  $i$  的适应度值;  $k$  为系数;  $N$  为种群个体数目。

采用实数交叉法进行交叉操作, 染色体  $a_k$  和  $a_l$  在  $j$  位的交叉操作方法, 其中  $b \in (0, 1)$ 。

$$\begin{cases} a_{kj} = a_{kj}(1-b) + a_{lj}b \\ a_{lj} = a_{lj}(1-b) + a_{kj}b \end{cases} \quad (12)$$

选取第  $i$  个个体的第  $j$  个基因  $a_{ij}$  进行变异操作, 方法如下

$$a_{ij} = \begin{cases} a_{ij} + (a_{ij} - a_{\max}) \cdot f(g) & r \geq 0.5 \\ a_{ij} + (a_{\min} - a_{ij}) \cdot f(g) & r < 0.5 \end{cases} \quad (13)$$

式中:  $f(g) = r_2(1 - g/G_{\max})$ ;  $r_2$  为一个随机数;  $g$  为迭代次数;  $G_{\max}$  为最大进化次数;  $r \in (0, 1)$ 。计算适应度函数值, 以 GA 输出的最优权值阈值作为 BP 神经网络初始权值阈值。

## 3 实验验证

实验通过以下两种指标来评价预测误差<sup>[23]</sup>, 分别是均方根误差(RMSE)和绝对平均误差(MAE), 其中, RMSE 用来衡量误差的分散程度, MAE 评价预测误差的平均幅度, 按照季节将 2014 年 9 月到 2015 年 9 月 30 台风机数据分成春、夏、秋、冬四组, 分别抽取 3、6、9、12 四个月的数据, 其中前 30 天作为训练数据, 第 31 天作为测试数据, 具体日期见表

3, 时间分辨率为 5 min。为了验证加特征值方法的优越性, 在保证每组数据不变的情况下, 分别用 ELM, LSSVM, GA-BP 三种方法训练。

3.1 确定阈值  $m$

分别使用春夏秋冬四组数据进行试验, 调整阈值  $m$  的大小, 实验得出 GA-BP, ELMF、LSSVMF、GA-BPF 三种方法在相同  $m$  值下四组数据的均值, 对比确定不同方法的最佳  $m$  值。分别取  $m = 0.1, m = 0.2, \dots, m = 1$ 。如表 2 所示, 其中, E 表示 ELM, L 表示 LSSVM, G 表示 GA-BP, ELMF、LSSVMF、GA-BPF(表 3 中分别用 EF, LF, GF 表示)分别表示添加特征值训练此三种模型的方法。

由表 2 可知, 通过对比在  $m$  值相同的情况下, 三种方法预测的 RMSE 的平均值, 可得当  $m = 0.3$  时, 三种模型预测的误差总体较小。

表 2 对比不同  $m$  取值的 RMSE

Table 2 Comparison of RMSE of different $m$				
方法	ELMF	LSSVMF	GA-BPF	Mean
$m$ 值	RMSE			
0.1	47.298	46.882	47.274	47.029
0.2	47.018	47.120	46.690	46.876
<b>0.3</b>	<b>46.892</b>	<b>46.560</b>	<b>46.596</b>	<b>46.682</b>
0.4	46.943	46.438	47.818	46.999
0.5	46.966	46.600	47.789	46.952
0.6	47.146	47.324	47.161	47.084
0.7	46.987	47.075	47.744	47.261
0.8	47.159	47.185	47.031	47.125
0.9	47.387	47.141	47.734	47.421
1.0	47.468	47.630	47.543	47.549

3.2 给风速加特征值方法的合理性

取  $m = 0.3$ , 首先给春夏秋冬四组数据的风速标记特征值, 并使用 ELM, LSSVM, GA-BP 三种方法, 得出三种方法在给风速加特征值和不加特征值两种情况下模型的预测精度, 如表 3 所示, 为三种方法在加特征值和不加特征值训练模型下的预测误差情况(RMSE)。

由表 3 可知, 在每组数据实验下, ELMF、LSSVMF、GA-BPF 三种方法的预测精度在 RMSE

和 MAE 两方面都优于 ELM、LSSVM、GA-BP; 由图 5 可知, ELMF、LSSVMF、GA-BPF 三种方法预测的绝对误差都有减小, 验证了在风电功率预测方法中引入风速升降特征的合理性。相比较 LSSVMF 方法的实验结果, ELMF 和 GA-BPF 方法在 RMSE 和 MAE 两方面提升较明显, 说明标记特征值方法对 ELM 和 GA-BP 两种方法的改善效果较好。相比较春季和秋季两组数据的实验结果, 夏季和秋季的预测精度在 RMSE 和 MAE 上提高都较为明显, 说明标记特征值对夏季和秋季风的发电功率预测效果较好, 因此本文所提出的根据风速升降特征, 给风速添加特征值的方法训练模型, 可以取得更高预测精度。




图 5 各个模型预测的绝对误差

Fig. 5 Prediction errors of different models

表 3 对比三种方法的 RMSE 和 MAE

Table 3 Comparison of RMSE & MAE of three methods

时间	RMSE		MAE		RMSE		MAE		RMSE		MAE	
	E	EF	E	EF	L	LF	L	LF	G	GF	G	GF
2015.03.01~2015.03.31	36.468	35.464	25.222	24.515	36.603	35.532	25.147	24.582	36.477	35.274	24.997	24.453
2015.06.01~2015.07.01	60.144	58.104	41.074	39.641	58.676	56.881	39.809	38.410	59.036	57.401	39.844	39.639
2014.09.01~2014.10.01	40.655	39.921	28.972	28.197	40.406	39.546	28.621	28.192	40.406	39.546	28.621	28.192
2014.12.01~2015.12.31	55.665	54.078	38.484	37.941	56.006	54.439	38.697	38.011	56.137	54.162	38.635	37.786
均值	50.759	46.892	33.438	32.573	47.923	46.560	33.068	32.299	48.014	46.596	33.024	32.517

## 4 结语

短期风电功率的有效预测是保证电网稳定运行的关键因素之一。本文根据风速升降的特征, 定义了上升风和下降风, 通过对比风速上升和下降时的功率变化, 说明风速升降对实际发电功率有较大影响, 提出了基于风速升降特征的短期风电功率预测方法。

该方法首先对比阈值  $m$  从 0.1 m/s 到 1 m/s 十种情况下的预测精度, 确定  $m$  值, 通过阈值  $m$  给风速添加特征值, 增加了训练样本维度, 从而训练模型。用上海某风电场的实测风速功率数据, 比较了 ELM、LSSVM 和 GA-BP 三种方法在给风速加特征值和不加特征值两种情况下的预测精度, 与不加特征值相比较, 加特征值后预测的精度明显提高, 验证了风速升降特征在风电功率预测中的合理性。

## 参考文献

- [1] JUNG J, BROADWATER R P. Current status and future advances for wind speed and power forecasting[J]. Renewable and Sustainable Energy Reviews, 2014, 31(2): 762-777.
- [2] 薛禹胜, 郁琛, 赵俊华, 等. 关于短期及超短期风电功率预测的评述[J]. 电力系统自动化, 2015, 39(6): 141-151.  
XUE Yusheng, YU Chen, ZHAO Junhua, et al. A review on short-term and ultra-short-term wind power prediction[J]. Automation of Electric Power Systems, 2015, 39(6): 141-151.
- [3] TASCIKARA OGLU A, UZUNOGLU M. A review of combined approaches for prediction of short-term wind speed and power[J]. Renewable & Sustainable Energy Reviews, 2014, 34(6): 243-254.
- [4] 李玲玲, 许亚惠, 田晓越, 等. 基于组合模型的风电功率短期预测[J]. 电工技术学报, 2014, 29(增刊 1): 475-480.  
LI Lingling, XU Yahui, TIAN Xiaoyue, et al. Based on the combined model of short-term wind power prediction[J]. Transactions of China Electrotechnical Society, 2014, 29(S1): 475-480.
- [5] 张宁宇, 高山, 赵欣. 一种考虑风电随机性的机组组合模型及其算法[J]. 电工技术学报, 2014, 28(5): 22-29.  
ZHANG Ningyu, GAO Shan, ZHAO Xin. A unit commitment model and algorithm with randomness of wind power[J]. Transactions of China Electrotechnical Society, 2014, 28(5): 22-29.
- [6] CHEN P, PEDERSEN T, BAK-JENSEN B, et al. ARIMA-based time series model of stochastic wind power generation[J]. IEEE Transactions on Power Systems, 2010, 25(2): 667-676.
- [7] 范高锋, 王伟胜, 刘纯. 基于人工神经网络的风电功率短期预测系统[J]. 电网技术, 2008, 32(22): 72-76.  
FAN Gaofeng, WANG Weisheng, LIU Chun. Artificial neural network based wind power short term prediction system[J]. Power System Technology, 2008, 32(22): 72-76.
- [8] CHEN D, GONG Q, JIN Z, et al. Short-term wind power prediction based on support vector regression machine optimized by adaptive disturbance quantum-behaved particle swarm optimization[J]. Power System Technology, 2013, 37(4): 974-980.
- [9] 李霄, 王昕, 郑益慧, 等. 基于改进最小二乘支持向量机和预测误差校正的短期风电负荷预测[J]. 电力系统保护与控制, 2015, 43(11): 63-69.  
LI Xiao, WANG Xin, ZHENG Yihui, et al. Short-term wind load forecasting based on improved LSSVM and error forecasting correction[J]. Power System Protection and Control, 2015, 43(11): 63-69.
- [10] 肖迁, 李文华, 李志刚, 等. 基于改进的小波-BP 神经网络的风速和风电功率预测[J]. 电力系统保护与控制, 2014, 42(15): 80-86.  
XIAO Qian, LI Wenhua, LI Zhigang, et al. Wind speed and power prediction based on improved wavelet-BP neural network[J]. Power System Protection and Control, 2014, 42(15): 80-86.
- [11] 刘爱国, 薛云涛, 胡江鹭, 等. 基于 GA 优化 SVM 的风电功率的超短期预测[J]. 电力系统保护与控制, 2015, 43(2): 90-95.  
LIU Aiguo, XUE Yuntao, HU Jianglu, et al. Ultra-short-term wind power forecasting based on SVM optimized by GA[J]. Power System Protection and Control, 2015, 43(2): 90-95.
- [12] WANG Jianzhou, WANG Yun, JIANG Ping. The study and application of a novel hybrid forecasting model - a case study of wind speed forecasting in China[J]. Applied Energy, 2015, 143: 472-488.
- [13] 陈烨, 高亚静, 张建成. 基于离散 Hopfield 模式识别样本的 GRNN 非线性组合短期风速预测模型[J]. 电力自动化设备, 2015, 25(8): 131-136.  
CHEN Ye, GAO Yajing, ZHANG Jiancheng. GRNN nonlinear combination model for short-term wind speed forecasting based on discrete Hopfield pattern

- recognition[J]. Electric Power Automation Equipment, 2015, 25(8): 131-136.
- [14] 叶林, 赵永宁. 基于空间相关性的风电功率预测研究综述[J]. 电力系统自动化, 2014, 38(14): 126-135.  
YE Lin, ZHAO Yongning. A review on wind power prediction based on spatial correlation approach[J]. Automation of Electric Power Systems, 2014, 38(14): 126-135.
- [15] 杨正瓴, 冯勇, 熊定方, 等. 基于季风特性改进风电功率预测的研究展望[J]. 智能电网, 2015, 3(1): 1-7.  
YANG Zhengling, FENG Yong, XIONG Dingfang, et al. Research prospects of improvement in wind power forecasting based on characteristics of monsoons[J]. Smart Grid, 2015, 3(1): 1-7.
- [16] 林鹏, 赵书强, 谢宇琪, 等. 基于实测数据的风电功率曲线建模及不确定估计[J]. 电力自动化设备, 2015, 35(4): 90-95.  
LIN Peng, ZHAO Shuqiang, XIE Yuqi, et al. Wind power curve modeling based on measured data and uncertainty estimation[J]. Electric Power Automation Equipment, 2015, 35(4): 90-95.
- [17] GANGER D, ZHANG J, VITTAL V. Statistical characterization of wind power ramps via extreme value analysis[J]. IEEE Transactions on Power Systems, 2014, 29(6): 3118-3119.
- [18] OUYANG T, ZHA X, QIN L. A survey of wind power ramp forecasting[J]. Energy & Power Engineering, 2013, 5(4): 368-372.
- [19] 张翌晖, 王贺, 胡志坚, 等. 基于集合经验模态分解和改进极限学习机的短期风速组合预测研究[J]. 电力系统保护与控制, 2014, 42(10): 29-34.  
ZHANG Yihui, WANG He, HU Zhijian, et al. A hybrid short-term wind speed forecasting model based on ensemble empirical mode decomposition and improved extreme learning machine[J]. Power System Protection and Control, 2014, 42(10): 29-34.
- [20] 翟敏, 张瑞, 王宇. 极限学习机(ELM)网络结构调整方法综述[J]. 西安文理学院学报(自然科学版), 2014, 17(1): 1-6.  
ZHAI Min, ZHANG Rui, WANG Yu. A summary of network structure adjustments of extreme learning machining[J]. Journal of Xi'an University of Arts & Science (Nat Sci Ed), 2014, 17(1): 1-6.
- [21] VAN GESTEL T, DE BRABANTER J, DE MOOR B, et al. Least squares support vector machines[M]. Singapore: World Scientific, 2002.
- [22] 罗毅, 刘峰, 刘向杰. 基于主成分—遗传神经网络的短期风电功率预测[J]. 电力系统保护与控制, 2012, 40(23): 47-53.  
LUO Yi, LIU Feng, LIU Xiangjie. Short-term wind power prediction based on principal component analysis and genetic neural network[J]. Power System Protection and Control, 2012, 40(23): 47-53.
- [23] 徐曼, 乔颖, 鲁宗相. 短期风电功率预测误差综合评价方法[J]. 电力系统自动化, 2011, 35(12): 20-26.  
XU Man, QIAO Ying, LU Zongxiang. A comprehensive error evaluation method for short-term wind power prediction[J]. Automation of Electric Power Systems, 2011, 35(12): 20-26.

收稿日期：2015-10-15； 修回日期：2015-12-05

作者简介：

叶小岭(1964-), 女, 教授, 硕士生导师, 研究方向为系统建模与最优化控制; E-mail: xyz.nim@163.com

陈浩(1992-), 男, 通信作者, 硕士研究生, 研究方向为短期风电功率预测; E-mail: chen943281546@163.com

郭晓杰(1988-), 男, 硕士研究生, 研究方向为短期风电功率预测。E-mail: gxj\_workmail@163.com

(编辑 周金梅)