

基于卷积神经网络的京津冀地区高分辨率格点预报偏差订正试验

张延彪^{①②} 宋林烨^{②*} 陈明轩^② 韩雷^{①②} 杨璐^②

① 中国海洋大学 山东 青岛 266100;

② 北京城市气象研究院 北京 100089

* 联系人, E-mail: lysong@ium.cn

2022-06-15 收稿, 2022-09-29 接受

北京市自然科学基金(8212025; 8222051); 国家重点研发计划项目(2018YFF0300102); 北京市气象局科技项目(BMBKJ202004011); 国家自然科学基金(42275012)

摘要 为了进一步提高 RISE 系统高分辨率网格化预报产品的准确率,同时考虑到深度学习近年来在地学领域的有效应用,采用 2019—2021 年高分辨率 RISE 系统数据,设计出卷积神经网络模型 Rise-Unet,实现了未来 4~12 h 地面 2 m 温度、2 m 相对湿度、10 m-U 风速以及 10 m-V 风速预报结果的订正。订正试验结果表明,采用均方根误差和平均绝对误差作为评分标准,与 RISE 原始预报结果相比,基于 Rise-Unet 模型可以有效提高温湿风预报结果的准确率。该基于深度学习的 Rise-Unet 偏差订正技术可应用于 RISE 系统的后处理模块,对提升 RISE 系统百米级分辨率或其他高分辨率模式系统格点预报水平具有重要的科学意义和应用价值。

关键词

天气预报;
深度学习;
高分辨率;
偏差订正

数值天气预报(Numerical Weather Prediction, NWP)自提出起至今已有 100 多年的时间(陈德辉和薛纪善 2004)。在这百余年时间里,数值天气预报技术实现飞跃式发展。最近十年来,政府和公众对于精细化网格天气预报预警的需求日益提升,数值天气预报产品和无缝隙融合集成预报产品在确保准确率的同时,其预报格点精度也在不断提高(金荣花等 2019)。由于天气系统的混沌性,无论何种建模方式均无法对其进行完整描述,故数值天气预报结果也不可避免存在误差。因此,研究各种信息后处理方法以提高天气预报准确率具有重要的科学价值和现实意义。

目前模式预报后处理订正方法可以分为两大类:传统方法与新兴方法。第一类传统方法主要以统计学理论以及历史资料为基础来实现订正。顾震潮(1958a, 1958b)指出历史资料在天气预报中的重要性。Klein et al.(1959)提出完全预报法(Perfect

Prognostic, PP)通过在观测值和模式预报值之间建立线性统计模型以完成订正。Glahn and Lowry (1972)提出模式输出统计法(Model Output Statistics, MOS)。与完全预报法相比, MOS 是通过建立观测值与相关气象要素数预报值之间的统计模型来实现订正效果,是气象部门常用的一种预报订正方法。Homleid(1995)使用卡尔曼滤波法实现预报偏差订正,该方法利用上一个时刻的预报误差反馈及时调整预报方程,因此只需使用上一个时刻的预报误差即可,与 MOS 方法相比,卡尔曼滤波法对历史资料并无严格要求,目前仍被应用于各个预报中心业务中。此后,钱维宏(2012)详细论证了历史信息在模式预报订正过程中的重要性,在此基础上, Peng et al.(2013)提出模式距平积分预报订正方法(Anomaly Numerical-correction with Observations, ANO),通过充分利用多年历史气象资料计算气候平均态实现数值模式预报结果订正。近年来,各种

引用格式: 张延彪, 宋林烨, 陈明轩, 等. 2022. 基于卷积神经网络的京津冀地区高分辨率格点预报偏差订正试验[J]. 大气科学学报, 45(6): 850-862.

Zhang Y B, Song LY, Chen M X et al. 2022. A study of error correction for high-resolution gridded forecast based on a convolutional neural network in the Beijing-Tianjin-Hebei Region[J]. Trans Atmos Sci, 45(6): 850-862. doi: 10.13878/j.cnki.dqkxxb.20220615001. (in Chinese).

机器学习和深度学习方法逐渐被应用到数值天气预报偏差订正任务中并取得突出的效果(孙全德等, 2019; Xia et al., 2020),也被广泛应用于气候领域(海滢和陈光华, 2019; 贺圣平等, 2021),即所谓第二类新兴方法。例如,国外学者 Marzban(2003)使用非线性神经网络对区域模式温度预报进行订正并取得显著的提升。Kusiak et al.(2013)分别使用回归树、支持向量机、多层感知机、随机森林以及 K 临近这 5 种机器学习算法进行降水估测,显示出机器学习算法对气象要素非线性建模的重要作用。国内学者智协飞等(2020, 2021)使用神经网络算法实现温度预报以及针对降水概率预报订正并取得较好的效果。Han et al.(2021)基于卷积神经网络创新性地提出 CU-Net 网络以实现对欧洲中心 ECMWF 多个气象要素格点预报结果的订正,所得结果与传统订正方法相比有明显提升,对智能格点预报业务产生较大影响。目前,中国气象局主推高分辨率气象格点数据预报业务,同时这也是未来数值天气预报的发展方向(潘留杰等, 2017)。深度学习方法,尤其是卷积神经网络(Hadji and Wildes, 2018)和循环神经网络(Graves, 2012),在时空格点数据处理方面有极大的优势。因此,本文将基于深度学习开展京津冀地区高分辨率格点预报偏差订正试验研究,以探索新兴方法在未来实现精细化精准天气预报方面的潜力和应用价值。

1 资料和方法

1.1 研究区域和资料说明

本文研究区域为京津冀地区,所采用的资料为睿思(RISE)系统 500 m 分辨率网格数据。RISE 系统全称为 Rapid-refresh Integrated Seamless Ensemble system,其研发和业务运行主要是为了满足不断提升的首都气象服务预报要求,尤其是实现 2022 年北京冬奥会对于“百米级分辨率、分钟级更新”短临预报的刚性需求。该系统是北京城市气象研究院研发的新一代客观短临集成预报系统,其早期主要吸收了 1 km 分辨率 INCA 系统(Haiden et al., 2011)的融合分析和预报策略,并研究和集成了一系列适用于京津冀地区和冬奥复杂山区地形下的短临客观分析和预报算法(程丛兰等, 2019; 宋林烨等, 2019; Song et al., 2019; 杨璐等, 2019, 2022; 陈康凯等, 2020; Yang et al., 2021)。RISE 系统于 2019 年汛期开始实时业务试验运行,2021 年 7 月 1 日通过中国气象局业务升级准入后开始正式业务化运行。

当前,RISE 系统可提供逐 10 min 快速更新的京津冀全域约 760 km×610 km 范围内 500 m 网格分辨率以及冬奥重点山区约 100 km×100 km 范围内 100 m 网格分辨率的客观分析和未来 0~12 h 乃至 24 h 确定性预报数据产品。该系统高时空分辨率的网格化温湿风及降水、降水相态等产品为北京 2022 年冬奥会气象保障服务提供了较好的高精度客观预报支撑,同时也可以为常规气象预报服务及其他行业应用提供较高品质的高分辨率短临无缝隙网格分析和预报产品。

本文选用了 2019 年 9 月—2021 年 9 月共 2 a 的预报场数据以及分析场数据进行试验,数据空间分辨率为 500 m,时间分辨率为 10 min,数据区域范围为 112.83°~120.28°E、35.86°~42.73°N(即京津冀地区),所获得的预报网格图大小为 1 521×1 221(南北方向×东西方向)。针对 2019 年 9—12 月的数据,绝大部分数据来自 RISE 系统实时运行搜集所得,但由于当时系统试验运行稳定性调试、实时观测资料接收缺失、服务器存储空间不足等原因导致存储数据有所缺失,因此本文试验过程中首先对该部分数据进行了系统回算以补全数据缺失。针对两年的数据,由于数据量较少以及预报时间分辨率较高会导致连续两个预报时次变化不明显等原因,因此文中选择每月 1—22 日每隔 30 min 时间间隔进行抽样的数据作为训练集来对深度学习网络进行训练;选择每月 23 日之后的数据作为测试集以评估网络模型的订正性能。

1.2 数据预处理

深度学习模型需要保证有充足的训练数据量,对于 RISE 数据,考虑到数据拼接的连续性,文中将原本 1 521×1 221 大小的格点图分割成为 507×407 的子图以增加试验样本量并减轻训练过程中硬件资源损耗。由于训练集需要在保证数据量的同时增加数据多样性以提高模型鲁棒性,因此本文试验采用随机分割方式,每张图分割 10 次后整个训练集数据增大 10 倍;对于测试集来说,则采用顺序分割的方式,每张图将会按顺序分割为 9 张子图,相当于测试集增大 9 倍数据量,最终数据集数目如表 1 所示。这里需要指出,随着 RISE 系统的发展,它们的预报结果精度也会不断提升,其中如果模式计算方法有重大更新时会造成更新前后模式预报误差特征出现明显差异。比如,RISE 系统采用睿图-短期模式(CMA-BJ,原 RMAPS-ST)作为背景场,由于模式背景场从 V1.0 更新为 V2.0(版本升级、模式循环频

次从 3 h 升级为 1 h、模式预报性能升级),RISE 系统在 2021 年底更换了系统计算的背景场,该操作在预报误差减小的同时也会造成新数据与旧数据误差分布规律出现明显的不一致性,这便会导致当前训练得到的模型对数值模式数据不适应,从而导致偏差订正效果下降,或者说基于训练得到的数值模式预报偏差模型的代表性会变差。因此在本文中均采用基于 CMA-BJ V1.0 版本背景场的 RISE 数据开展格点偏差订正研究和训练测试,而在后续的实际应用中需要考虑使用最新的模式数据对模型进行补充训练和重新调整,以增强模型对预报误差的适应能力。

表 1 数据集样本划分

Table 1 Division of the dataset

RISE 数据	数据尺寸	训练集数	测试集数
增强前	1 521×1 221	25 000	7 900
增强后	507×407	25 000×10	7 900×9

1.3 算法建模

深度学习中的计算机视觉方向一般指代图像处理问题,因此对于气象格点数据,可将其每个格点的处理转换为图像中的像素点处理,进而将其总体转换为计算机视觉领域中的图像处理问题。图像处理问题一般表现为输入待处理图像、输出后处理图像的形式,因此本文神经网络的输入为当前时刻的实况格点图及当前时刻预报格点图,输出为当前预报时效订正图。以 RISE 系统 2021 年 12 月 29 日 09

时 30 分起报时刻为例,其 4 h 预报时刻为 2021 年 12 月 29 日 13 时 30 分,则输入数据包括 12 月 29 日 09 时 30 分的分析场数据以及当前时刻起报的 4 h 预报场(即 12 月 29 日 13 时 30 分)数据结果,网络要学习的结果为 12 月 29 日 13 时 30 分的分析场数据,即网络的真实值。

U-Net 模型(Ronnberger et al., 2015)作为一种基于卷积网络结构的深度学习分割网络,其结构简单并在各个领域取得了较好的效果。本文基于 U-Net 模型结构,研发了针对高分辨率大尺寸图像进行调整而形成的卷积神经网络 Rise-Unet,其输入为当前时刻观测值以及预报值的组合特征,输出则为订正结果,Rise-Unet 模型总体结构如图 1 所示。已有研究指出,在 CU-Net 模型订正实验中加入观测值对于提升模型性能有重要作用(Han et al., 2021),因此本文模型输入中包含了当前时刻观测值。从图 1 可以看出,Rise-Unet 包括编码模块、解码模块与复制拼接模块三部分。其中左半部分为编码模块,主要包含下采样池化操作和卷积操作,提取图像高层次特征的同时有效减小特征图的尺寸,节约计算资源。例如输入图像尺寸为 507×407,经编码操作后大小变为 64×64。右半部分为解码模块,与编码模块作用相反,解码模块通过不断地卷积和上采样操作,将特征图的尺寸恢复至 507×407。复制拼接操作则是将编码器与解码器的特征图做通道拼接,进而可以将同一层中编码模块提取的低层次特征与解码模块提取的高层次特征进行融合叠加,




图 1 Rise-Unet 网络结构图

Fig.1 The structure of Rise-Unet

使得模型输出能够保留来自较浅层的细粒度信息,如编码器 $64 \times 254 \times 204$ 的特征图与解码器 $64 \times 254 \times 204$ 的特征图拼接后所获得的新特征图大小为 $128 \times 254 \times 204$ 。后文中将展示该网络对于 500 m 分辨率 RISE 数据的处理效果。

1.4 试验设置

本文采用均方根误差 R_{MSE} (Root Mean Square Error, RMSE) 以及平均绝对误差 M_{AE} (Mean Absolute Error, MAE) 来衡量预报订正结果与观测值之间的差距,其中 MAE 反映两个数据集之间的真实误差,而 RMSE 由于是对误差先进行平方累加后再进行开方计算,可评价数据的离散程度,该操作本质上放大了两个数据集的大误差部分,因此 RMSE 的值越小,则表示两者之间的最大误差较小。两者计算方式如式(1)和(2)所示。

$$R_{MSE} = \sqrt{\frac{1}{n} \sum_{i=0}^n (y_i - \hat{y}_i)^2}, \quad (1)$$

$$M_{AE} = \frac{1}{n} \sum_{i=0}^n |y_i - \hat{y}_i|. \quad (2)$$

其中: n 表示测试集样本数目; y_i 表示测试集观测值; \hat{y}_i 表示预报订正结果。

RISE 系统预报技术路线中,快速融合和吸收了逐 10 min 更新的实况观测信息,在 1~3 h 预报时效,系统本身对温湿风等常规天气要素的预报误差已相对较小,因此从实际业务应用角度来说,耗费大量计算机资源和运行时间成本做深度学习订正 1~3 h 格点预报结果的必要性并不大。所以,本文使用收集到的 RISE 数据,针对其 4~12 h 高分辨率预报结果进行订正,将最终各时效订正结果与原始预报结果进行分季节对比以探索该方法对高分辨率精细化网格预报订正中的有效性。需要指出,考虑到不同预报时效误差分布存在一定差异,因此文中分别针对 4~12 h 中的每个时效建立订正模型。根据传统四季划分方法,文中的冬季包括 12 月—次年 2 月,春季包括 3—5 月,夏季包括 6—8 月,秋季包括 9—11 月。

文中所有模型训练使用的反向传播优化器均为 Adam (Kingma and Ba, 2014), 因为该算法所需内存较小且计算更高效。为进一步提高计算效率与模型的鲁棒性,需对网络进行批训练处理。试验中,模型参数初始化参考 CU-Net (Han et al., 2021), 针对 RISE 数据的试验批处理量为 8, 所有网络初始学习率 r 均设置为 0.001, 网络学习率衰减因子均设置为 0.5; 衰减具体实现方式为若验证集连续两次评分指

标没有下降,则学习率将会衰减为 $0.5 \times r$; 训练总迭代次数为 10 次,对于所获得的模型在测试集进行测试并选择最优结果。

2 试验结果

2.1 地面 2 m 温度订正结果

对于 RISE 数据集的地面 2 m 温度 4~12 h 预报时效的订正结果如图 2 所示。可以发现,针对 MAE 以及 RMSE 两种评价指标,使用 Rise-Unet 卷积网络对于各时效均明显表现为正向订正的效果,说明该模型对于高分辨率 2 m 温度格点预报场各时效订正均是有效的。订正前,温度 6~12 h 预报误差 RMSE 均在 2°C 以上,MAE 则均在 1.5°C 以上;但是基于 Rise-Unet 订正之后,所有 4~12 h 预报时效的平均 MAE 和 RMSE 下降至 1.4°C 和 1.9°C 以下。通过统计误差减小百分比结果可知,订正后各预报时效平均误差减小率为 20% 左右(图 2)。其中,针对 6 h 预报结果 RMSE 以及 MAE 的订正效果相对而言均是最为明显的,误差减小率约为 23%;对于 4~6 h 的订正结果随预报时效延长其减小率呈上升趋势,这可能是由于 6 h 误差分布较为稳定且相比之前时刻的误差较为明显,故导致网络参数拟合较好,能够稳定学习误差分布信息;而针对 6 h 之后预报结果的订正则趋于稳定且效果有所降低,在 18% 到 22% 之间,通过分析原始预报误差可以发现 7~12 h 的原始预报误差较大且较为稳定。RISE 系统 0~12 h 温度预报技术方案主要依次采用线性外推预报方法为主、线性外推预报和模式预报权重融合方法、模式预报为主,其中模式权重(外推权重)随预报时效呈指数型增长(衰减),且各个格点的临界预报时效阈值并不固定,每个时刻每个格点根据具体所在时间和所处位置的温度和云预报等情况进行动态调整,但一般而言 7 h 以后主要以单一的模式背景场预报占主导,因此考虑可能是由于系统原始温度预报数据计算方案或者插值方式导致了这种订正效果,同时这也导致 7~12 h 预报模型网络学习到的误差分布也是相似的,因此订正的效果基本趋于稳定。

图 3 为针对 RISE 研究的京津冀区域,给出了订正前后提前 4 h 的地面 2 m 温度预报 RMSE 空间分布对比结果。可以看到,针对图中的每个格点,该方法基本都有正向订正的效果,且订正后的图像相比原来误差分布更为均匀,这说明神经网络对研究区域全图有效,且卷积操作能对误差进行有效平滑




图 2 地面 2 m 温度各预报时效订正曲线: (a) 订正前后的 RMSE; (b) 订正前后的 MAE

Fig.2 Correction curve of 2-m temperature of RISE data at each prediction time: (a) the RMSE before and after correction; (b) the MAE before and after correction

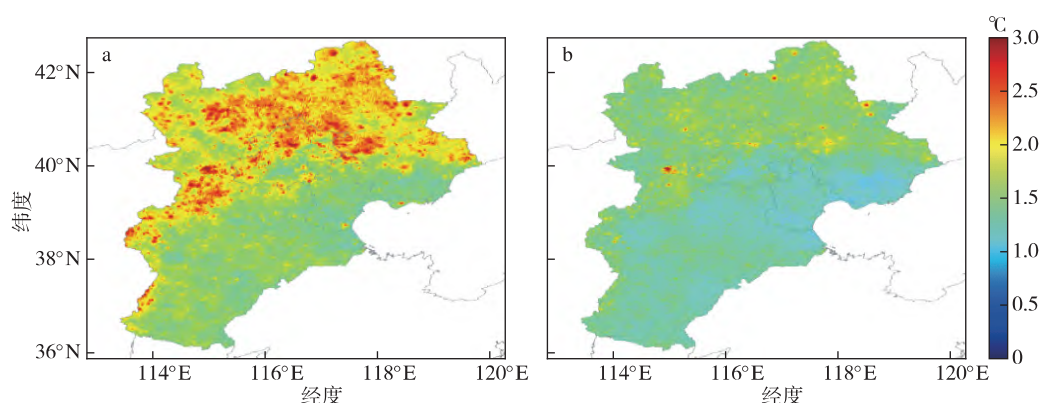


图 3 地面 2 m 温度 4 h 预报全年 RMSE 分布(单位: °C): (a) 订正前的原始预报误差; (b) 订正后的预报误差

Fig.3 Annual mean RMSE distribution of 2-m surface temperature for the 4-hour forecast (unit: °C): (a) the original forecast error; (b) the forecast error after correction

处理。图 3b 中所展现的订正效果总体表现为西北和北部地区误差较高,东南区域误差较低,这与原始预报结果的误差分布(图 3a)是基本保持一致的。这可能是由于 RISE 系统温度预报误差空间分布特征和京津冀地形结构之间存在较为紧密的联系。京津冀地处华北平原北部,北靠燕山山脉,西倚太行山,南面华北平原,东临渤海湾,西北和北面地形较高,南面和东面地形较为平坦。因此在研究区域里,西北和北部方向多为海拔较高的山区,且地形结构和山脉走势十分复杂,导致针对这些区域原始 RISE 温度预报误差较高,而东南方向多为平原,所以针对这些地形较低的区域原始温度预报误差相对较低(图 3a)。经过 Rise-UNet 订正之后,不仅整个京津冀区域温度预报误差较原始 RISE 预报显著降低,而且这一“西北高-东南低”的误差分布结构也相对有所减弱(图 3b)。

进一步分析四个不同季节的订正前后误差对比结果。表 2 以及图 4 分别为 4 h 预报订正结果的数

据统计表以及分季节 RMSE 空间分布。可以看到,针对春、夏、秋、冬四个季节误差减小率分别为 18.94%、17.68%、23.88%、23.28%(表 2),均表现为正向订正的效果,说明该网络对于此研究区域的订正能力全年有效。针对原始预报结果,夏季 RMSE 平均误差最小为 1.64,其余季节误差较大且仍主要分布于西北和北部山地区域。针对订正结果,夏季订正后的误差为 1.35,仍最小,但是相比于其他季节,其订正误差减小率为 17.68%,为四个季节中最低;秋季预报误差在订正前较高,为 1.80,但其订正误差减小率为 23.88%,为四个季节中最高。同时,秋季温度误差分布区域相比其余季节并没有呈现“锋线”状分布,而是较均匀的平铺状分布,考虑神经网络中的卷积操作对于均匀状误差分布订正效果较为明显,可能是秋季订正效果最显著的主要原因。另外,不论订正前还是订正后,四季中春季的温度预报误差都保持最大,这可能与春季京津冀地区气温内部变率大有一定的联系。

表2 地面2 m温度4 h预报RMSE四季订正统计

Table 2 RMSE results of 2-m surface temperature for the 4-hour forecast in different seasons

季节	订正前/℃	订正后/℃	减小率/%
春季	1.90	1.54	18.94
夏季	1.64	1.35	17.68
秋季	1.80	1.37	23.88
冬季	1.89	1.45	23.28

2.2 地面2 m相对湿度订正结果

对于地面2 m相对湿度,RISE系统4~12 h预报时效的订正结果如图5所示。针对MAE以及RMSE两种评价指标,总体来看与2 m温度订正结果相似,Rise-Unet模型对于各个预报时效均为

正向订正,订正后MAE和RMSE误差均减小,说明其对于高分辨率2 m相对湿度格点预报场订正是有效的。各预报时次平均误差减小率约为16%,其中针对8 h预报的订正MAE提高最为明显,约为17%(图5b),说明该时刻预报结果相比于实况的真实误差降低最为显著;而对于7 h预报结果订正RMSE降低最为明显,约为17.5%(图5a),说明该时刻网络对于格点图中的大误差区域订正效果较好。8 h之后,两种评价指标订正效果均开始下降,且之后几个订正时刻的效果处于稳定状态,这是由于原始预报误差从8 h之后始终保持在一个水平上,这同样与上文中地面2 m温度订正效果相似,说明该时间段神经网络对于误差的拟合效果也是趋于稳定的。

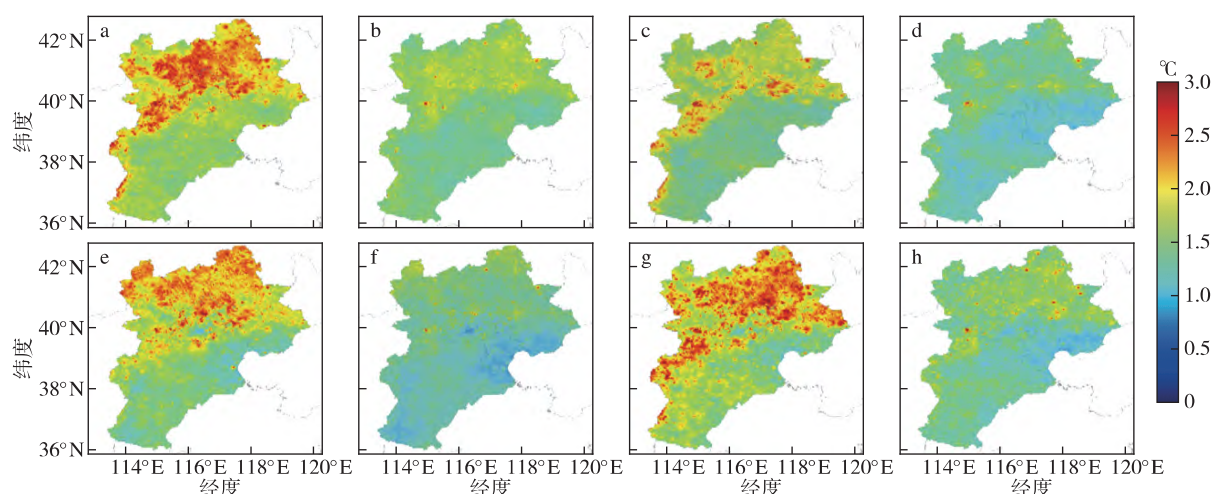


图4 春(a、b)、夏(c、d)、秋(e、f)、冬(g、h)地面2 m温度4 h预报的RMSE分布(单位:℃):(a、c、e、g)订正前;(b、d、f、h)订正后

Fig.4 RMSE distribution of 2-m surface temperature for the 4-hour forecast in different seasons (unit: °C): (a) and (b), (c) and (d), (e) and (f), (g) and (h) are forecast errors in spring, summer, autumn, and winter before and after correction respectively




图5 地面2 m相对湿度各预报时效订正曲线:(a)订正前后的RMSE;(b)订正前后的MAE

Fig.5 Correction curve of 2-m relative humidity of RISE data at each prediction time: (a) the RMSE before and after correction; (b) the MAE before and after correction

针对 RISE 研究区域 给出了 4 h 预报时效的 2 m 相对湿度预报订正结果的全年平均 RMSE(图 6) 。从图 6 可以看到 ,Rise-Unet 模型针对全年订正的每个格点基本均表现为正向提升效果 ,且订正后的图像相比原来误差分布更为均匀 ,这说明神经网络对地面 2 m 相对湿度的订正全图有效 ,订正效果总体表现为西北高原山区误差较高 ,东南平原以及临海区域误差较低(图 6) 。

表 3 及图 7 为 4 h 预报订正结果的分季节 RMSE 统计表以及空间分布。相对湿度与温度订正效果相似 ,四个季节 RMSE 误差减小率分别为 12. 81%、16. 77%、12. 64% 以及 14. 07% ,针对四个季节均为正向订正的效果 ,说明卷积神经网络对于研究区域中地面 2 m 相对湿度的订正能力不同季节均有效。对于原始 RISE 系统预报结果 ,夏季误差最小为 9. 48% ,其余季节误差较大且误差相似 ,各季节误差大值中心仍主要分布于西北山地区域(图 7) 。针对订正结果 ,与温度结果不同 ,夏季订正结果误差最小并且误差减小率为四季节中最高 ,其余三个季节订正效果大致相似。

表 3 地面 2 m 相对湿度 4 h 预报 RMSE 四季订正统计
Table 3 RMSE results of 2-m relative humidity for the 4-hour forecast in different seasons

季节	订正前 /%	订正后 /%	减小率 /%
春季	10. 23	8. 92	12. 81
夏季	9. 48	7. 89	16. 77
秋季	10. 44	9. 12	12. 64
冬季	10. 23	8. 79	14. 07

2.3 地面 10 m-U 风订正结果

对于 RISE 系统地面 10 m-U 风速 4~12 h 预报

时效的订正结果如图 8 所示。通过 Rise-Unet 网络订正之后 ,各时效的 10 m-U 风 RMSE 和 MAE 预报误差均降低 ,其中订正后 4~12 h 预报平均 RMSE 基本都下降至 1. 5 m/s 以下 ,平均 MAE 则基本下降至 1. 1 m/s 以下(图 8) 。这说明 Rise-Unet 网络对 RISE 系统风速预报订正表现为正向订正的效果 ,该方法针对高分辨率网格化 10 m-U 风速的订正效果是有效的。从图 8 中还可以看出 ,各预报时效平均误差减小率约为 15% ,其中针对 9 h 预报结果 MAE 订正效果最为明显 ,说明该时刻订正结果与实况值真实误差降低最为显著 ,针对 6 h 预报结果 RMSE 订正效果最为明显 ,说明针对该时刻误差较大的区域订正效果最为显著。9 h 以后订正效果趋于稳定 ,考虑仍为系统对于长时间预报计算以及插值误差趋于稳定所造成。

图 9 为针对 RISE 研究区域 ,地面 10 m-U 风速提前 4 h 预报订正结果的全年 RMSE 分布。可以看到 ,风速的原始误差分布较为集中 ,主要分布于西北以及西部省界区域 ,这是由于该区域为高原以及山脉分布区 ,因此针对该区域风速预报难度较大、预报效果较差(图 9a) 。但是 ,Rise-Unet 网络模型总体提升效果仍较为明显 ,经过格点订正后的 RMSE 在西北、北部及西部山区显著减小 ,在东南部平原大范围地区 RMSE 也大幅下降至 1 m/s 以下。

表 4 以及图 10 分别为 4 h 预报订正结果的分季节 RMSE 统计以及空间分布 ,由表 4 可知 Rise-Unet 网络模型方法针对春夏秋冬四个季节 RMSE 误差减小率分别为 14. 68%、16. 89%、10. 52% 以及 15. 00% ,均表现为正向订正的效果 ,这说明神经网络对于 10 m-U 风预报结果的订正能力不同季节都有效。对于原始 RISE 预报结果 ,U 风在秋冬季节

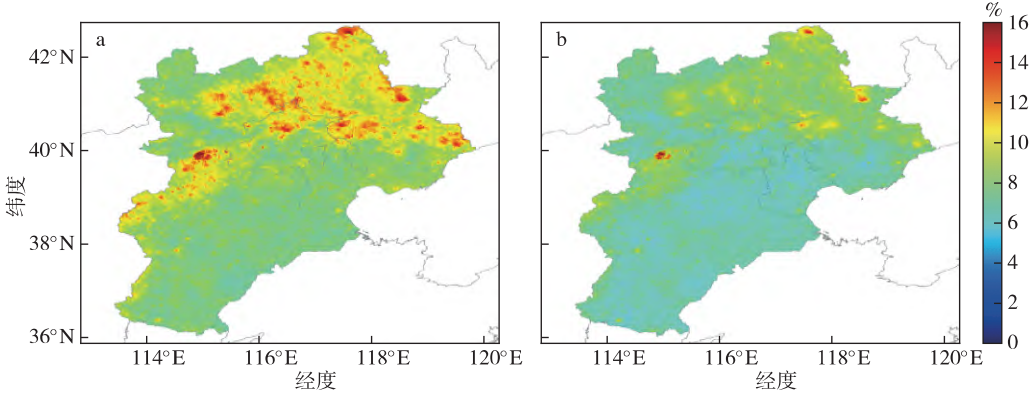


图 6 地面 2 m 相对湿度 4 h 预报全年 RMSE 分布(单位: %) : (a) 订正前的原始预报误差; (b) 订正后的预报误差

Fig.6 Annual mean RMSE distribution of 2-m relative humidity for the 4-hour forecast (unit: %) : (a) the original forecast error; (b) the forecast error after correction

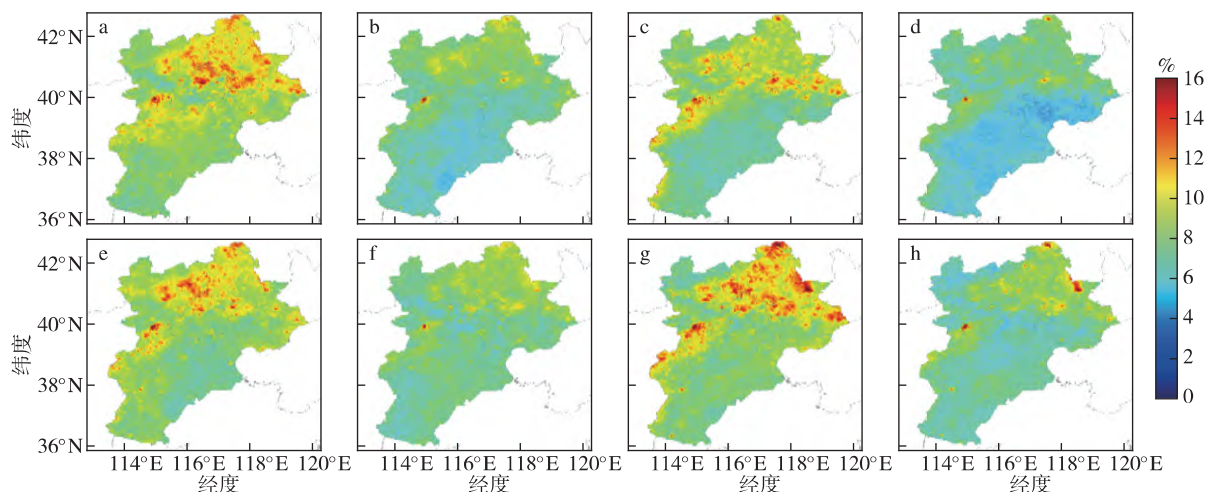


图7 春(a、b)、夏(c、d)、秋(e、f)、冬(g、h)地面2 m相对湿度4 h预报RMSE分布(单位: %):(a、c、e、g)订正前;(b、d、f、h)订正后

Fig.7 RMSE distribution of 2-m relative humidity for the 4-hour forecast in different seasons (unit: %):(a) and (b) (c) and (d) (e) and (f) (g) and (h) are forecast errors in spring summer autumn and winter before and after correction respectively

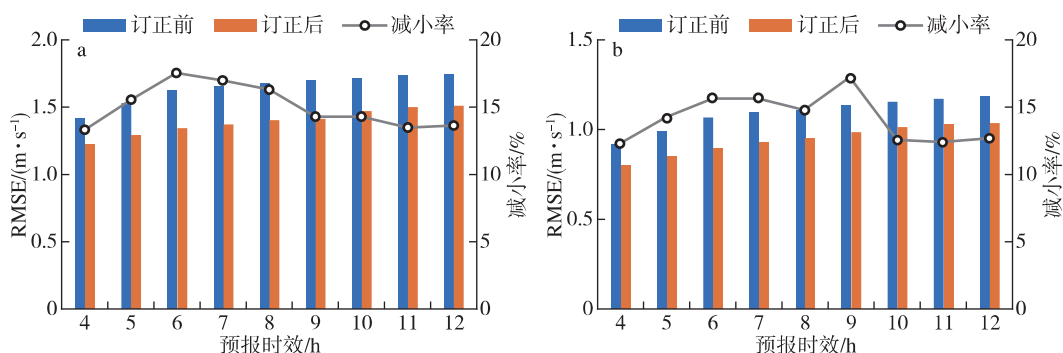


图8 地面10 m-U风各预报时效订正曲线:(a)订正前后的RMSE;(b)订正前后的MAE

Fig.8 Correction curve of 10-m U wind speed of RISE data at each prediction time:(a) the RMSE before and after correction;(b) the MAE before and after correction

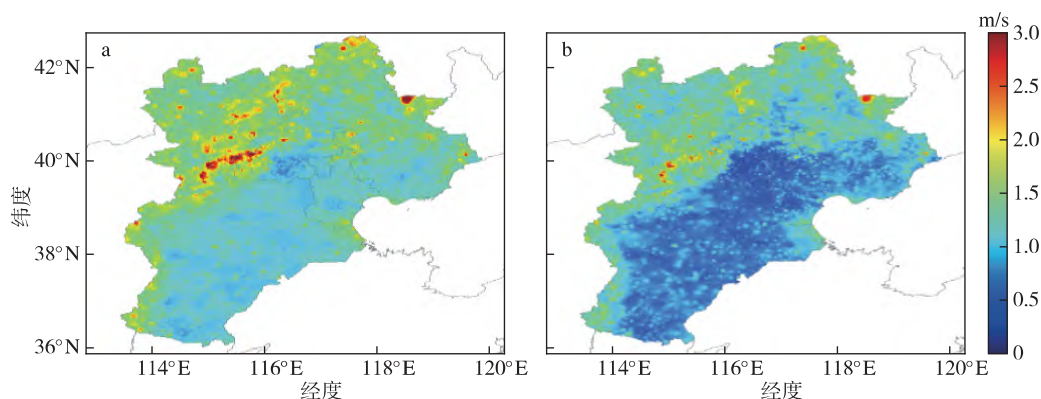


图9 地面10 m-U风4 h预报全年RMSE分布(单位: m/s):(a)订正前后的RMSE;(b)订正前后的MAE

Fig.9 Annual mean RMSE distribution of 10-m U wind speed for the 4-hour forecast (unit: m/s):(a) the RMSE before and after correction;(b) the MAE before and after correction

误差较小,分别为1.14 m/s和1.20 m/s,夏季误差为1.48 m/s,为四季中最大,但是Rise-UNET模型对

于夏季U风格点预报订正误差减小率最高,误差总体减少了16.89%(表4)。

表 4 地面 10 m-U 风速 4 h 预报分季订正统计

Table 4 RMSE results of 10-m *U* wind speed for the 4-hour forecast in different seasons

季节	订正前/($\text{m} \cdot \text{s}^{-1}$)	订正后/($\text{m} \cdot \text{s}^{-1}$)	减小率/%
春季	1.43	1.22	14.68
夏季	1.48	1.23	16.89
秋季	1.14	1.02	10.52
冬季	1.20	1.02	15.00

2.4 地面 10 m-V 风订正结果

RISE 系统的地面 10 m-V 风速 4~12 h 预报时

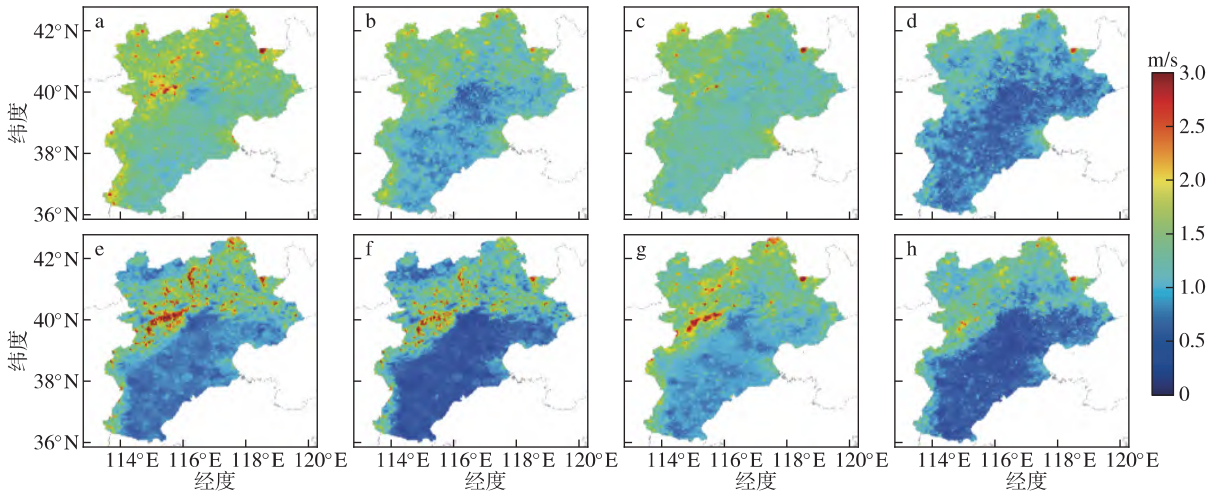


图 10 春(a、b)、夏(c、d)、秋(e、f)、冬(g、h)地面 10 m-U 风 4 h 预报 RMSE 分布(单位: m/s): (a、c、e、g) 订正前; (b、d、f、h) 订正后

Fig.10 RMSE distribution of 10-m *U* wind speed for the 4-hour forecast in different seasons (unit: m/s): (a) and (b) (c) and (d) (e) and (f) (g) and (h) represent forecast errors in spring, summer, autumn and winter before and after correction, respectively

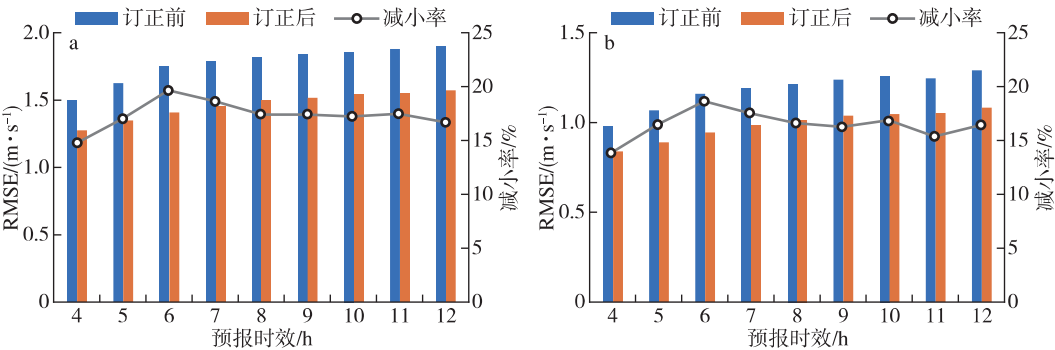


图 11 地面 10 m-V 风各预报时效订正曲线: (a) 订正前后的 RMSE; (b) 订正前后的 MAE

Fig.11 Correction curve of 10-m *V* wind speed of RISE data at each prediction time: (a) the RMSE before and after correction; (b) the MAE before and after correction

图 12 为针对 RISE 研究的京津冀区域,提前 4 h 预报的 10 m-V 风格点预报订正结果的全年 RMSE。通过对比订正前和订正后的误差空间分布结构,可

效的订正结果如图 11 所示。可以发现,针对 MAE 以及 RMSE 两种评价指标,使用 Rise-UNet 网络对于各时效均表现为正向订正的效果,说明该方法针对高分辨率 10 m-V 纬向风速的订正效果同样是有有效的。各时效平均误差减小率约为 18%,这相比于 10 m-U 风的订正效果(约 15%)更好。针对 RMSE 以及 MAE 两种评价指标均为 6 h 预报结果订正效果最为显著,之后订正效果出现下降并逐渐趋于平稳(图 11),考虑仍是因为系统对长期预报误差大且结果稳定的原因。

以看到图中基本每个格点均有正向提升效果,尤其是针对西北部区域,绝大部分 RMSE 超过 2.5 m/s 的各个局地山区纬向风速预报误差大值中心均减小

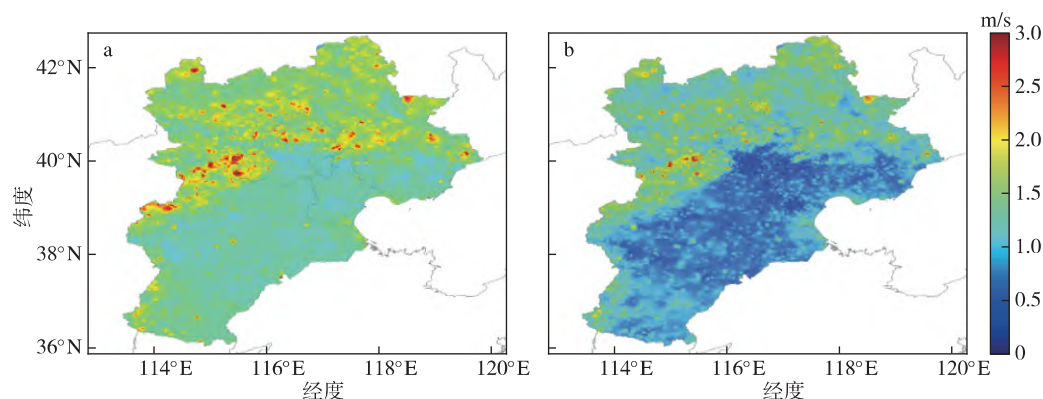


图 12 地面 10 m- V 风 4 h 预报全年 RMSE 分布(单位: m/s): (a) 订正前的原始预报误差; (b) 订正后的预报误差

Fig.12 Annual mean RMSE distribution of 10-m V wind speed for the 4-hour forecast(unit: m/s): (a) the original forecast error; (b) the forecast error after correction

到 2.5 m/s 以下,而京津冀东南平原地区的 RMSE 基本都降低至 1 m/s 以下(图 12b)。上述结果说明,与 10 m- U 风相似,Rise-Unet 神经网络对 10 m- V 风的订正仍然全图有效。另外,对比 U 风和 V 风之间的差异,可以发现原始 RISE 系统对 V 风的预报误差整体大于 U 风(图 12a、图 9a),而订正后两者误差相对更为接近。

表 5 以及图 13 分别为 4 h 预报订正结果的分季节 RMSE 统计以及空间分布。针对四个季节,RISE 系统 10 m- V 风的原始预报误差总体都比 10 m- U 风更大(表 4.5)。其中春季 V 风误差大于 U 风的特征最为突出(图 13a 图 10a)。但是,针对春夏秋这三个季节,地面 10 m- V 风的订正误差减小率分别为 16.56%、17.94%和 10.74%,均比 10 m- U 风的订正提升率相对更高;而针对冬季的订正结果,10 m- V 风误差减小率则为 12.82%,小于 10 m- U 风的误差减小率(15.00%)。总体上来看, U 风和 V 风两种要素误差分布是一致的,且 Rise-Unet 神经网络对 10 m- V 风的订正与 10 m- U 风相似,仍是全季节有效的。

表 5 地面 10 m- V 风速 4 h 预报分季订正统计

Table 5 RMSE results of 10-m V wind speed for the 4-hour forecast in different seasons

季节	订正前/($\text{m} \cdot \text{s}^{-1}$)	订正后/($\text{m} \cdot \text{s}^{-1}$)	减小率/%
春季	1.63	1.36	16.56
夏季	1.56	1.28	17.94
秋季	1.21	1.08	10.74
冬季	1.17	1.02	12.82

3 讨论和结论

本文基于 RISE 系统高分辨率短临预报数据

集,使用卷积神经网络构建了 Rise-Unet 模型进行京津冀区域 500 m 分辨率格点温湿风预报订正试验和评估检验,探索深度学习算法在高分辨率格点数据预报订正中的应用效果,主要结论如下:

1) 针对 RISE 系统数据研究区域,使用 Rise-Unet 网络调整以及迁移后可以有效地完成京津冀全区域订正,同时针对各个季节该模型也均表现出其显著的正向订正效果,不同季节订正后温度、湿度、风速误差减小率分别在 17%~24%、12%~17%、10%~18%,说明该模型对高分辨率、细网格气象预报数据具有十分有效的偏差订正能力。因此,这对于深度学习在高分辨率格点预报数据偏差订正中的应用以及推动气象预报精细化发展方面具有重要意义。

2) 在对 RISE 系统数据多个气象要素的订正中,发现预报误差大值区主要集中分布于京津冀西部以及北部高原和山地区域。对温度而言,由于西部地区地形复杂且温差较大,因此对于该区域温度的预报以及订正结果误差相对较高,而东部地区多平原且温差变化特征较为稳定,因此预报和订正的误差相对较小。对相对湿度而言,与温度类似。对于 RISE 系统地面 10 m- U 风和 10 m- V 风预报产品,由于高原山地区域,风的局地特征较为复杂且日变化大,而且数值模式的可预报性较低,因此对其订正的误差也较大。

本文提出的 Rise-Unet 网络模型格点偏差订正方法可应用于 RISE 系统的后处理模块,以进一步提升 RISE 系统的格点预报水平。需要指出,本文只针对了地面常规要素开展基于深度学习的高分辨率格点预报订正方法研究和试验,考虑到 RISE 系统除了可以提供高分辨率温湿风等常规天气要素短

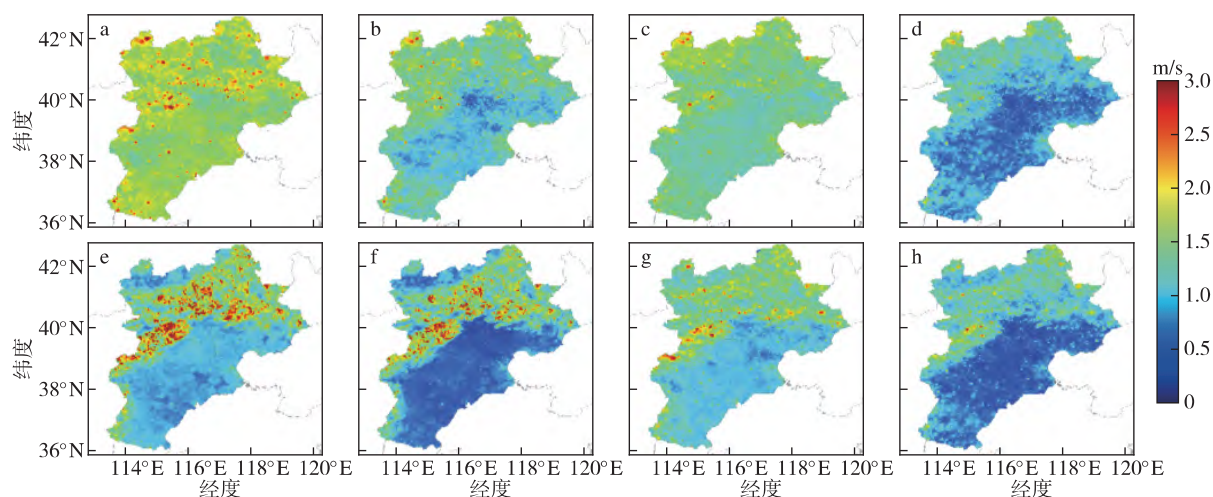


图 13 春(a、b)、夏(c、d)、秋(e、f)、冬(g、h) 地面 10 m-V 风 4 h 预报 RMSE 分布(单位: m/s): (a、c、e、g) 订正前; (b、d、f、h) 订正后

Fig.13 RMSE distribution of 10-m V wind speed for the 4-hour forecast in different seasons(unit: m/s): (a) and (b) (c) and (d) (e) and (f) (g) and (h) represent forecast errors in spring, summer, autumn and winter before and after correction, respectively

临预报结果之外,还可以提供地面降水、降水相态、零度层高度、雪线高度等要素的高分辨率未来预报。因此,未来可以进一步研究 Rise-Unet 网络或其他深度学习方法对其他高分辨率天气要素格点预报的偏

差订正效果。除此之外,本文研究结论不仅可直接应用于 RISE 系统,也可以为提升其他高分辨率模式系统格点预报水平提供一定的理论和技术参考。

参考文献(References)

- 程丛兰, 陈敏, 陈明轩, 等. 2019. 临近预报的两种高时空分辨率定量降水预报融合算法的对比试验[J]. 气象学报, 77(4): 701-714. Cheng C L, Chen M, Chen M X, et al. 2019. Comparative experiments on two high spatiotemporal resolution blending algorithms for quantitative precipitation nowcasting[J]. Acta Meteorol Sin, 77(4): 701-714. (in Chinese).
- 陈德辉, 薛纪善. 2004. 数值天气预报业务模式现状与展望[J]. 气象学报, 62(5): 623-633. Chen D H, Xue J S. 2004. An overview on recent progresses of the operational numerical weather prediction models[J]. Acta Meteorol Sin, 62(5): 623-633. (in Chinese).
- 陈康凯, 宋林烨, 杨璐, 等. 2020. 一种基于高斯模糊的复杂地形下高分辨率三维插值方法的研究与试验应用[J]. 高原气象, 39(2): 367-377. Chen K K, Song L Y, Yang L, et al. 2020. Research and application of a three-dimensional interpolation method for high-resolution temperature in complex terrain based on Gaussian fuzzy[J]. Plateau Meteorol, 39(2): 367-377. doi: 10. 7522/j. issn. 1000-0534. 2019. 00108. (in Chinese).
- Glahn H R, Lowry D A. 1972. The use of model output statistics (MOS) in objective weather forecasting[J]. J Appl Meteor, 11(8): 1203-1211. doi: 10. 1175/1520-0450(1972) 011<1203: tuomos>2. 0.co; 2.
- Graves A. 2012. Supervised sequence labelling with recurrent neural networks[J]. Studies in Computational intelligence.
- 顾震潮. 1958a. 作为初值问题的天气形势数值预报与由地面天气历史演变作预报的等值性[J]. 气象学报, 29(2): 93-98. Gu Z C. 1958a. On the equivalency of formulations of weather forecasting as an initial value problem and as an “evolution” problem[J]. Acta Meteorol Sin, 29(2): 93-98. (in Chinese).
- 顾震潮. 1958b. 天气数值预报中过去资料的使用问题[J]. 气象学报, 29(3): 176-184. Gu Z C. 1958b. On the utilization of past data in numerical weather forecasting[J]. Acta Meteorol Sin, 29(3): 176-184. (in Chinese).
- Hadji I, Wildes R P. 2018. What do we understand about convolutional networks? [EB/OL]. [2022-10-11]. https://arxiv.org/abs/1803.08834.
- 海滢, 陈光华. 2019. 利用神经网络模型预测西北太平洋热带气旋生成频数[J]. 气候与环境研究, 24(3): 324-332. Hai Y, Chen G H. 2019. Prediction of frequency of tropical cyclones forming over the western north Pacific using an artificial neural network model[J]. Clim Environ Res, 24(3): 324-332. (in Chinese).
- Haiden T, Kann A, Wittmann C, et al. 2011. The integrated nowcasting through comprehensive analysis (INCA) system and its validation over the eastern alpine region[J]. Wea Forecasting, 26(2): 166-183. doi: 10. 1175/2010waf2222451. 1.
- Han L, Chen M X, Chen K K, et al. 2021. A deep learning method for bias correction of ECMWF 24-240 h forecasts[J]. Adv Atmos Sci, 38(9): 1444-1459.

- 贺圣平,王会军,李华,等.2021.机器学习的原理及其在气候预测中的潜在应用[J].大气科学学报,44(1):26-38. He S P,Wang H J,Li H,et al. 2021.Machine learning and its potential application to climate prediction[J].Trans Atmos Sci,44(1):26-38.doi:10.13878/j.cnki.dqkxxb.20201125001.(in Chinese).
- Homleid M.1995.Diurnal corrections of short-term surface temperature forecasts using the Kalman filter[J].Wea Forecasting,10(4):689-707.doi:10.1175/1520-0434(1995)010<0689:dcosts>2.0.co;2.
- 金荣花,代刊,赵瑞霞,等.2019.我国无缝隙精细化网格天气预报技术进展与挑战[J].气象,45(4):445-457. Jin R H,Dai K,Zhao R X,et al., 2019.Progress and challenge of seamless fine gridded weather forecasting technology in China[J].Meteor Mon,45(4):445-457.doi:10.7519/j.issn.1000-0526.2019.04.001.(in Chinese).
- Kingma D P,Ba J.2014.Adam: a method for stochastic optimization[C]//International Conference on Learning Representations.Ithaca.
- Klein W H,Lewis B M,Enger I.1959.Objective prediction of five-day Mean temperatures during winter[J].J Meteor,16(6):672-682.doi:10.1175/1520-0469(1959)016<0672:opofdm>2.0.co;2.
- Kusiak A,Wei X P,Verma A P,et al. 2013.Modeling and prediction of rainfall using radar reflectivity data: a data-mining approach[J].IEEE Trans Geosci Remote Sens,51(4):2337-2342.doi:10.1109/TGRS.2012.2210429.
- Marzban C.2003.Neural networks for postprocessing model output: ARPS[J].Mon Wea Rev,131(6):1103-1111.doi:10.1175/1520-0493(2003)131<1103:nnfpmo>2.0.co;2.
- 潘留杰,薛春芳,王建鹏,等.2017.一个简单的格点温度预报订正方法[J].气象,43(12):1584-1593. Pan L J,Xue C F,Wang J P,et al. 2017.A simple grid temperature forecast correction method[J].Meteor Mon,43(12):1584-1593.doi:10.7519/j.issn.1000-0526.2017.12.015.(in Chinese).
- Peng X D,Che Y Z,Chang J.2013.A novel approach to improve numerical weather prediction skills by using anomaly integration and historical data[J].Journal of Geophysical Research,118(16):8814-8826.
- 钱维宏.2012.如何提高天气预报和气候预测的技巧? [J].地球物理学报,55(5):1532-1540. Qian W H.2012.How to improve the skills of weather and climate predictions? [J].Chin J Geophys,55(5):1532-1540.(in Chinese).
- Ronneberger O,Fischer P,Brox T.2015.U-net: convolutional networks for biomedical image segmentation[EB/OL].[2022-10-07].https://arxiv.org/abs/1505.04597.
- 宋林烨,陈明轩,程丛兰,等.2019.京津冀夏季雷达到量降水估测的误差统计及定量气候校准[J].气象学报,77(3):497-515. Song L Y,Chen M X,Cheng C L,et al. 2019.Characteristics of summer QPE error and a climatological correction method over Beijing-Tianjin-Hebei region[J].Acta Meteorol Sin,77(3):497-515.(in Chinese).
- Song L Y,Chen M X,Gao F,et al. 2019.Elevation influence on rainfall and a parameterization algorithm in the Beijing area[J].J Meteorol Res,33(6):1143-1156.
- 孙全德,焦瑞莉,夏江江,等.2019.基于机器学习的数值天气预报风速订正研究[J].气象,45(3):426-436. Sun Q D,Jiao R L,Xia J J,et al., 2019.Adjusting wind speed prediction of numerical weather forecast model based on machine learning methods[J].Meteorol Mon,45(3):426-436.doi:10.7519/j.issn.1000-0526.2019.03.012.(in Chinese).
- Xia J J,Li H C,Kang Y Y,et al. 2020.Machine learning-based weather support for the 2022 winter olympics[J].Adv Atmos Sci,37(9):927-932.
- Yang L,Chen M X,Wang X L,et al. 2021.Classification of precipitation type in North China using model-based explicit fields of hydrometeors with modified thermodynamic conditions[J].Wea Forecasting,36(1):91-107.doi:10.1175/waf-d-20-0005.1.
- 杨璐,陈敏,陈明轩,等.2019.高时空分辨率三维风场在强对流天气临近预报中的融合应用研究[J].气象学报,77(2):243-255. Yang L,Chen M,Chen M X,et al. 2019.Fusion of 3D high temporal and spatial resolution wind field and its application in nowcasting of severe convective weather[J].Acta Meteorol Sin,77(2):243-255.(in Chinese).
- 杨璐,宋林烨,荆浩,等.2022.复杂地形下高精度风场融合预报订正技术在冬奥会赛区风速预报中的应用研究[J].气象,48(2):162-176. Yang L,Song L Y,Jing H,et al. 2022.Fusion prediction and correction technique for high-resolution wind field in winter Olympic games area under complex terrain[J].Meteor Mon,48(2):162-176.(in Chinese).
- 智协飞,王田,季焱.2020.基于深度学习的中国地面气温的多模式集成预报研究[J].大气科学学报,43(3):435-446. Zhi X F,Wang T,Ji Y, 2020.Multimodel ensemble forecasts of surface air temperature over China based on deep learning approach[J].Trans Atmos Sci,43(3):435-446.doi:10.13878/j.cnki.dqkxxb.20200219003.(in Chinese).
- 智协飞,张珂珂,田烨,等.2021.基于神经网络和地理信息的华东及华南地区降水概率预报[J].大气科学学报,44(3):381-393. Zhi X F,Zhang K J,Tian Y,et al. 2021.Probabilistic precipitation forecast in East and South China based on neural network and geographic information[J].Trans Atmos Sci,44(3):381-393.doi:10.13878/j.cnki.dqkxxb.20210117001.(in Chinese).

A study of error correction for high-resolution gridded forecast based on a convolutional neural network in the Beijing-Tianjin-Hebei Region

ZHANG Yanbiao^{1,2}, SONG Linye^{2*}, CHEN Mingxuan², HAN Lei^{1,2}, YANG Lu²

1. Ocean University of China, Qingdao 266100, China;

2. Institute of Urban Meteorology, CMA, Beijing 100089, China

Precise weather monitoring and accurate weather forecast are two of the most decisive factors for the success of the Winter Olympics. Considering the particularity of the 2022 Beijing Winter Olympic Games (the only Winter Olympic Games held under the climate dominated by the continental East Asian winter monsoon and the only Winter Olympic Games held in inland areas) and the rigid demand for the goal of “hundred-meter resolution and minute-updated level” high-precision forecast, the Beijing Institute of Urban Meteorology has developed a new generation of the Rapid-refresh Integrated Seamless Ensemble system—RISE—that can provide 500-and even 100-m resolution spatial grid forecast data products with 10-min updated frequency for the Beijing Winter Olympics. In order to improve the prediction accuracy of the RISE system, and considering the successful use of deep learning in the field of geoscience in recent years, this paper develops a convolution neural network-based model, Rise-Unet, using the high-resolution RISE data from 2019 to 2021 to correct the prediction results of 2-m surface temperature, 2-m relative humidity, 10-m U wind speed, and 10-m V wind speed for a lead time of 4–12 hours. The root-mean-square error and mean absolute error are employed to evaluate the accuracy of the model in this study. By comparing with the original prediction results of the RISE system, it is proven that the deep learning-based model, Rise-Unet, can effectively improve the accuracy of high-resolution gridded prediction results. The method proposed in this study can be applied as the post-processing module of the RISE system, which has important scientific significance and application value for improving the gridded prediction level of the RISE system as well as other high-resolution numerical weather forecasting systems.

weather forecasting; deep learning; high resolution; bias correction

doi: 10.13878/j.cnki.dqkxxb.20220615001

(责任编辑: 刘菲)